

Tarea individual — Caso de estudio integrador

RutaExpress: análisis descriptivo de una operación de última milla

Complementa los temas trabajados en la Sesión 1 (análisis descriptivo). Aplica lo visto en clase: la operación logística de una empresa de entregas de última milla.

1. Contexto de negocio

RutaExpress es una startup de entregas de última milla (last-mile delivery) que acaba de cerrar una ronda de inversión Serie A. Opera con una flota mixta de bicicletas, motocicletas, automóviles y, de forma piloto, drones de reparto en algunas zonas de la ciudad.

La Dirección de Operaciones te contrata como analista de datos para responder, con evidencia estadística, tres preguntas que están sobre la mesa del comité directivo:

- ¿Vale la pena invertir en expandir la flota de drones más allá del piloto actual?
- ¿Qué zona de la ciudad requiere una intervención operativa prioritaria?
- ¿Qué meta de tiempo de entrega (SLA) es razonable comunicar públicamente a los clientes, sin comprometer la reputación de la marca?

Para resolverlas, el equipo de operaciones te compartió un extracto de 1,500 envíos recientes con información de zona, vehículo, nivel de servicio, distancia, peso, tiempo de entrega, incidencias, calificación del cliente y costo.

2. Diccionario de datos

La siguiente tabla describe cada variable del dataset. Nota que, deliberadamente, no se incluye una columna de "tipo de variable": clasificarlas es parte de tu trabajo en la Parte A.

Variable	Descripción	Unidad / Categorías
envio_id	Identificador único del envío	Numérico secuencial (no analizar)
zona_entrega	Zona de la ciudad donde se entregó el paquete	Centro, Norte, Sur, Poniente, Oriente
tipo_vehiculo	Vehículo usado para realizar la entrega	Bicicleta, Motocicleta, Automóvil, Dron
nivel_servicio	Nivel de servicio contratado por el cliente	Estándar, Prioritario, Express
distancia_km	Distancia recorrida entre el centro de distribución y el destino	Kilómetros
peso_paquete_kg	Peso del paquete entregado	Kilogramos
tiempo_entrega_min	Tiempo total transcurrido desde que el paquete sale del centro de distribución hasta que llega al cliente	Minutos
paquetes_repartidor_dia	Número de paquetes que entregó ese repartidor durante el día del envío	Conteo de paquetes

incidencias_reportadas	Número de incidencias registradas durante ese envío (tráfico, dirección incorrecta, cliente ausente, etc.)	Conteo de incidencias
calificacion_cliente	Calificación que el cliente dio al servicio recibido	Escala de 1 a 5 estrellas
costo_envio_mxn	Costo total cobrado al cliente por el envío	Pesos mexicanos (MXN)

3. Generación de los datos

Copia y ejecuta el siguiente código en una celda de Jupyter Notebook para generar el dataset simulado. La semilla aleatoria está fijada, así que todos obtendrán exactamente los mismos datos.

```
import numpy as np
import pandas as pd

np.random.seed(2026)
n_envios = 1500

zona_entrega = np.random.choice(
    ["Centro", "Norte", "Sur", "Poniente", "Oriente"],
    size=n_envios, p=[0.30, 0.20, 0.20, 0.15, 0.15]
)

tipo_vehiculo = np.random.choice(
    ["Bicicleta", "Motocicleta", "Automóvil", "Dron"],
    size=n_envios, p=[0.30, 0.40, 0.25, 0.05]
)

nivel_servicio = np.random.choice(
    ["Estándar", "Prioritario", "Express"],
    size=n_envios, p=[0.55, 0.30, 0.15]
)

distancia_km = np.random.gamma(shape=3.0, scale=1.8, size=n_envios).round(2)
peso_paquete_kg = np.random.gamma(shape=2.0, scale=1.1, size=n_envios).round(2)
paquetes_repartidor_dia = np.random.poisson(lam=14, size=n_envios)
incidencias_reportadas = np.random.poisson(lam=0.4, size=n_envios)

calificacion_cliente = np.random.choice(
    [1, 2, 3, 4, 5], size=n_envios, p=[0.03, 0.07, 0.15, 0.35, 0.40]
)

factor_vehiculo = pd.Series(tipo_vehiculo).map({
    "Bicicleta": 6.5, "Motocicleta": 3.8, "Automóvil": 4.5, "Dron": 2.0
}).values

tiempo_base = distancia_km * factor_vehiculo + np.random.normal(5, 3, n_envios)

factor_zona = pd.Series(zona_entrega).map({
    "Centro": 1.0, "Norte": 1.05, "Sur": 1.35, "Poniente": 1.1, "Oriente": 1.15
}).values

tiempo_entrega_min = tiempo_base * factor_zona
tiempo_entrega_min += incidencias_reportadas * np.random.uniform(15, 45, n_envios)
```

```

tiempo_entrega_min = np.clip(tiempo_entrega_min, 4, None).round(1)

costo_envio_mxn = (25 + distancia_km * 4.2 + peso_paquete_kg * 3.0 +
                  (nivel_servicio == "Express") * 35 +
                  (nivel_servicio == "Prioritario") * 15 +
                  np.random.normal(0, 5, n_envios)).round(2)
costo_envio_mxn = np.clip(costo_envio_mxn, 20, None)

df = pd.DataFrame({
    "envio_id": range(1, n_envios + 1),
    "zona_entrega": zona_entrega,
    "tipo_vehiculo": tipo_vehiculo,
    "nivel_servicio": nivel_servicio,
    "distancia_km": distancia_km,
    "peso_paquete_kg": peso_paquete_kg,
    "tiempo_entrega_min": tiempo_entrega_min,
    "paquetes_repartidor_dia": paquetes_repartidor_dia,
    "incidencias_reportadas": incidencias_reportadas,
    "calificacion_cliente": calificacion_cliente,
    "costo_envio_mxn": costo_envio_mxn,
})

df.head()

```

Librerías necesarias: numpy, pandas, scipy (para sesgo y curtosis) y matplotlib / seaborn (para las gráficas). Son las mismas que usamos en la Sesión 1.

4. Instrucciones generales

- Resuelve el caso en un Jupyter Notebook. Incluye el código, las salidas (números y gráficas) y un texto de interpretación para cada pregunta — el código solo no es suficiente.
- Cada respuesta de interpretación debe estar redactada como si se la fueras a presentar a alguien del negocio, no a otro analista: evita explicar la fórmula, explica lo que significa el resultado.
- Puedes reutilizar y adaptar el código visto en la Sesión 1 (groupby, agg, coeficiente de variación, histogramas, KDE).

Parte A — Conceptos y tipos de variable

1. Clasifica cada una de las variables del dataset (tipo y subtipo: numérica continua/discreta, categórica nominal/ordinal).
2. El equipo de sistemas de RutaExpress está considerando guardar nivel_servicio como un número (1 = Estándar, 2 = Prioritario, 3 = Express) para "ahorrar espacio" en la base de datos. Si un analista junior calculara el promedio de esa columna numérica y reportara "el nivel de servicio promedio es 1.6", ¿qué error de interpretación estaría cometiendo? ¿Qué sí sería válido hacer con esa codificación numérica y qué no?

Parte B — Medidas de tendencia central

1. Calcula la media, la mediana y la moda de tiempo_entrega_min. ¿Cuál de las tres describe mejor el tiempo "típico" de entrega? Explica por qué el equipo de Operaciones NO debería usar la media si quiere fijar una promesa de tiempo de entrega (SLA) al cliente.

2. La Dirección General quiere anunciar públicamente "entregamos en X minutos" como parte de una campaña de marketing. Con base en tus resultados, ¿qué valor de X recomendarías y qué medida descriptiva sustenta tu recomendación?
3. Calcula la mediana de tiempo_entrega_min por tipo de vehículo. ¿Qué vehículo tiene el mejor desempeño de tiempos? Con ese resultado, ¿qué decisión operativa (por ejemplo, sobre el tamaño o composición de la flota) le propondrías al Director de Operaciones?

Parte C — Medidas de dispersión

1. Calcula la desviación estándar y el coeficiente de variación de tiempo_entrega_min. En tus palabras: ¿qué tan consistente es el servicio de entrega de RutaExpress?
2. Compara el coeficiente de variación del tiempo de entrega entre las cinco zonas. Si una zona tiene una media de tiempo similar a las demás pero un coeficiente de variación notablemente más alto, ¿qué significa eso para la experiencia del cliente en esa zona, y qué acción operativa priorizarías ahí?
3. Calcula el coeficiente de variación de costo_envio_mxn para cada nivel de servicio (Estándar, Prioritario, Express). ¿El servicio Express es más o menos predecible en su costo que el Estándar? ¿Qué implicación tiene esto si RutaExpress quiere ofrecer un precio fijo garantizado por nivel de servicio?

Parte D — Medidas de sesgo y curtosis

1. Calcula el sesgo y la curtosis de tiempo_entrega_min. Interpreta el resultado: ¿qué tan frecuentes son las entregas "problemáticas" (con retrasos muy por encima del resto) en comparación con una distribución simétrica?
2. Si el sesgo de tiempo_entrega_min resulta alto, ¿qué le recomendarías al equipo de datos antes de usar esta variable directamente en un futuro modelo predictivo de tiempos de entrega, sin ninguna transformación?
3. Desde el punto de vista de riesgo operativo: si la curtosis es alta, ¿qué implica eso sobre la probabilidad de que ocurran retrasos extremos (aunque poco frecuentes)? ¿Cómo debería influir este resultado en el diseño de una política de compensación o reembolso por entregas tardías?

Parte E — Visualización de datos

1. Construye un histograma de tiempo_entrega_min y marca con líneas verticales la media y la mediana. Describe en un par de líneas la forma de la distribución que observas (¿simétrica?, ¿con cola hacia algún lado?) y relacionala con el sesgo que calculaste en la Parte D.
2. Construye, en un mismo gráfico, la densidad (KDE) de tiempo_entrega_min para dos zonas que tú elijas (por ejemplo, la de mejor y la de peor desempeño según la Parte C). ¿Qué diferencia visual encuentras entre ambas curvas, y qué decisión de negocio podrías sustentar con esa comparación?

Parte F — Síntesis y decisión gerencial

1. Redacta un memo ejecutivo de máximo 200 palabras, dirigido al Director de Operaciones de RutaExpress, en el que respondas las tres preguntas planteadas en la Sección 1 (expansión de drones, zona prioritaria, meta de SLA). Cada recomendación debe estar sustentada en al menos una medida descriptiva concreta que hayas calculado (no basta con opiniones generales).

2. Menciona al menos una limitación de tu análisis que el Director debería tener en cuenta antes de tomar la decisión final (por ejemplo, relacionada con el tamaño de la muestra, variables que no están en el dataset, o el hecho de que este es solo un análisis descriptivo y no uno inferencial o causal).

5. Formato de entrega

- Un único archivo .ipynb con código, salidas y texto de interpretación en celdas de Markdown.
- Nombra el archivo como: Apellido_Nombre_CasoEstudio_sesion1.ipynb (si lo trabajan de a parejas, nombrar Apellido1_Nombre1_y_Apellido2_Nombre2_CasoEstudio_sesion1.ipynb)
- Antes de entregar, ejecuta el notebook completo de principio a fin (Kernel → Restart & Run All) para asegurarte de que no tiene errores.